

Project Part 1,2,3

ΑΝΔΡΕΑΣ ΟΙΚΟΝΟΜΑΚΗΣ 115200800272

ΔΗΜΗΤΗΣ ΣΑΝΤΟΠΙΝΑΙΟΣ 115200800282

Το πρόγραμμα κάνει compile με την εντολή make και του δίνεται ως όρισμα ποιο part να εκτελέσει.

Πχ >make

gcc -o SD-2014-All_Parts SD-2014-All_Parts.c GraphLib.c graph_functions.c hfunctions.c

Statistics.c Query1.c Query2.c Query3.c Query4.c Tread_Uilities.c Forum_graph.c

Community_Graph_Uilities.c Clique_Uilities.c GN_Algorithm.c Parts.c CHECKS.c -pthread

./SD-2014-All_Parts 1 για το 1ο part

./SD-2014-All_Parts 1 για το 2ο part

./SD-2014-All_Parts 1 για το 3ο part

Σημείωση: Δεν είναι δυνατόν να σταλθούν και τα dataset των part 1 /2 λόγω μεγέθους οπότε θα πρέπει να τοποθετηθούν κατά την εξέταση στους αντιστοιχούς φακέλους για το κάθε part :
dataset2,dataset3

Αρχικά θα εξηγηθούν κάποια πράγματα τα οποία ήταν να υλοποιηθούν στα προηγούμενα parts και υλοποιήθηκαν μετά.

1) ReachNodeN/Resultset / next

```
struct resultSet {  
    struct VQueue *Visited_Queue; //ουρά επισκεψης  
    struct Cell *Visited_hash; //hash table που κρατα το id των κομβων που εχουμε επισκεφθει  
}resultSet;
```

Η ReachNodeN δημιουργεί την δομή Resultset , αρχικοποιεί τα Visited_Queue και Visited_hash επισκέπτεται όλους τους γείτονες του ζητούμενου κόμβου και τους βάζει στην ουρά και στο hash table που προαναφέρθηκαν και τους δίνει μια απόσταση dist + 1 όπου το dist είναι μέλος της δομής Node και έχει αρχικοποιηθεί με 0 για τον κομβό που ζητήσαμε.

Η next εξάγει από την ουρά τον τρέχον κομβό και επισκεπτεται όλους τους γείτονες του που δεν έχουμε ήδη επισκεφθεί και τους βάζει στην ουρά και το hash table και στην συνέχεια επιστεφει στην δομή pair το ID και το distance. Η διαδικασία σταματά όταν η ουρά δεν έχει άλλους κομβούς

2) Bidirectional Search για την ReachNode1

Βρίσκεται στο αρχείο graph_functions.c στη γραμμή 559 και υλοποιεί την διαδικασία με 2 hash_table , ένα για τον κομβό έναρξης και ένα για τον κομβό τέλους εκτελώντας διαδοχικά bfs από την αρχή και μετά από το τέλος μέχρι να συναντηθούν σε κάποιο κομβό και έπειτα να αθροίσει τις αποστάσεις και να βρει το τελικό shortest_path

3)Query 4

Η ιδέα γενικότερα είναι ότι κάθε forum περιέχεται σε ένα hash table στον γράφο και εκράζεται ως ένας κομβός Fnode:

```
struct FNode{  
    int id; id του Forum  
    char name[MAX_STRING_LENGTH]; ονομα του forum
```

```

struct GNodeList *Forum_Members; λιστα με μέλη του forum
struct Cell *likes_to_from; hash table με likes σε κάποιον απο καποιον
struct Cell *replies_to_from; hash table με replies σε κάποιον απο καποιον
}

```

Τα δυο αυτά hash table περιέχουν κομβους τυπου TNode των οποίων τα id αντιστοιχουν στους κομβους του γραφου που εχουν δεχθει like / reply απο κάποιον και στη συνεχεια αυτοι οι κομβοι Tnode περιεχουν εναν δεικτη σε hash table που και αυτα με τη σειρά τους εχουν κομβους Tnode των οποίων τα id αντιστοιχουν σε κομβους γράφου οι οποίοι εχουν κανει like / reply και εχουν ενα δεικτη στις δομες like_counter / reply_counter αντιστοιχα και έτσι εχουμε την πληροφορία σε ποιον εχει γινει like / reply απο ποιον σε κάθε forum.

Για την ευρεση του trust χρησιμοποιειται η συναρτηση estimateTrust η οποια για την περιήγηση στον γράφο χρησιμοποιει την Reachnode12 η οποια βρισκει τα συντομότερα μονοπάτια σε κατευθυνομενο γραφο μιας και δεν υπαρχει εξασφάλιση οτι η ακμή είναι διπλή.

Περιγραφή Part 3

→ Χρήση των Threads

Για τη χρήση νημάτων έχουμε επιλέξει να υλοποιήσουμε ένα threadpool και οι υλοποιήσεις που χρησιμοποιουν τα threads υπάρχουν στο αρχει Tread_Uilities. Ακολουθεί μια συντομη περιγραφή για το πως λειτουργει η διαδικασία ευρεσης και δημιουργίας γράφων για τα top forums συμφωνα με το μέγεθος των μελών τους.

Τα threads ξεκινουν να δουλεουν με το που μπει μια δουλεια στην ουρά του threadpoll μεσω της Add_Job_To_ThreadPoll η οποία περναι την συναρτηση με τα ορισματα σε μια δομη tsk_args για να τα χρησιμοποιήσουνε τα threads.

Για την ευρεση των Nforums χρησιμοποιειται μια λιστα στην οποία γράφουν τα threads τα Nforums. Η λιστα αυτή λειτουργει συμφωνα με 2 μεταβλήτες οι οποίες κρατούν το μεγιστο αριθμό των μελών των forum που εχουν μπει και τον αντιστοιχο ελάχιστο έτσι ώστε να ξερει το προγραμμα αν θα πρεπει να μπει το forum στη λιστα αυτη ή οχι. Στην περιπτωση που μπει (η λιστα εισαγει τα στοιχεια ταξινομημένα) αφαιρείται το τελευταιο στοιχειο της λιστας και η ελαχιστη τιμή των μελων του forum αποκτα την τιμή του αμέσως μικρότερου.

Τα threads για την καταμέτρηση και εισαγωγή στη λίστα με τα Nforums χρησιμοποιουν την συνάρτηση Find_Nforums.

Τα threads για την δημιουργία των γράφων χρησιμοποιουν την συνάρτηση Create_F_Graphs.

Το main thread κανει suspend χρησιμοποιοντας mutex/cond_var αρχικά για την ευρεση των Nforums και στην συνέχεια για την δημιουργια των γράφων για καθε forum.

Η εγγραφή στις κοινες δομές (critical section) προστατευεται και αυτή με mutex semaphores.

->Clique Percolation Method

Ο Αλγόριθμος προσεγγιστηκε ως εξής:

Καθε κομβος του γράφου του γράφου είναι υποψήφια 1-clique εκτως απο αυτους που εχουν λιγότερους απο k-1 γειτονες.

Όλες αυτές οι υποψήφιες κλίκες αποθηκεύονται σε μια λίστα και μέσω αυτής της λίστας παράγονται οι 2-cliques μέσω κριτηρίων ελέγχου και η διαδικασία συνεχίζει δημιουργώντας μια άλλη λίστα με τις $k+1$ cliques μέχρι να φτάσουμε στο επιθυμητό μέγεθος κλίκας. Κάθε κλίκα που δημιουργείται έχει ένα μοναδικό id το οποίο παραγεται από τον αριθμό εισαγωγής (ins_num) του κόμβου. Πχ έστω οι 3 κόμβοι με τα id και τα ins_num τους

id 5 ins_num 1
id 8 ins_num 2
id 2 ins_num 3

εάν αυτοί οι κόμβοι αποτελέσουν μια κλίκα [2,5,8] το id της θα είναι το 123 το οποίο παραγεται από την συνάρτηση Fix_Clique_id. Τα ins_num ταξινομούνται οπότε εάν έχει ήδη βρεθεί η παραπάνω κλίκα, η κλίκα [5,8,2] θα αγνοηθεί αφού είναι στην ουσία η ίδια κλίκα με το ίδιο id 123.

Στη συνέχεια οι κλίκες που βρέθηκαν εισάγονται σε ένα υπεργράφο (SuperGraph) και συνδέονται σύμφωνα με τα κριτήρια του αλγορίθμου.

Τα communities είναι κάθε συνεκτικό γράφημα του υπεργράφου και εισάγονται στην δομή Communities.

->Αλγόριθμος Girvan-Newman

Ο γράφος κρατάει ένα hash table με ids όλων των ακμών οι οποίοι παράγονται πάλι από τα ins_num πχ 2 κόμβοι με τα ins_num τους

id 89 ins_num 1
id 900 ins_num 2

οπότε η ακμή τους θα έχει id 12 είτε είναι η 89-900 είτε είναι η 900-89.

Το edge betweenness υπολογίζεται περίπου όπως και το betweenness centrality ενός κόμβου μόνο που κρατείται ένα hash table το οποίο αντιστοιχεί τα ids των ακμών με τον αριθμό που έχουν εμπλακεί ως γεφυρές οι συγκεκριμένες ακμές. (edge_bet_counter). Το ποιες ακμές έχουν εμπλακεί μας το δείχνει μια λίστα Engaged_Edges_List που περιέχει ακμές στην οποία βάζει τιμές η e_find_All_possible_path η οποία εσωτερικά κάνει report το μονοπάτι που ακολουθήθηκε. Τα edge_bet_counter αρχικοποιούνται όταν αλλάζει ένα state το οποίο παίρνει τιμές όσες φορές έχει τρέξει ο αλγόριθμος. Τέλος ο αλγόριθμος σταματάει όταν το modularity αρχίζει να φθίνει ή όταν πάρει την μέγιστη τιμή του.